

Roadmap de reducción de coste por tokens

Criterio que gobierna todo el documento: el objetivo no es gastar menos tokens, es **reducir el coste por capítulo de calidad aceptable**. Una medida que abarata la generación y multiplica las reescrituras, o que degrada la continuidad, no ahorra nada.

Cada medida que ponga en riesgo la coherencia va marcada con △.

Fase 1 · Inventario

Agentes con modelo

Agente	Modelo	Cuándo corre
Entrevistador	—	Una vez por novela
Planificador + Revisor	—	Una vez, hasta 3 rondas
Escritor	Fable	Por capítulo, más cada reescritura
Editor	Opus 5.5	Por capítulo, seis notas
Juez	Opus 5.5, fijo por obra	Desempate de INV-03, INV-11, INV-14
Resumidor	Haiku	Por capítulo aceptado

Sin modelo por diseño: Orquestador, Ensamblador de contexto, Consolidador, Verificador de reglas. Lo que resuelve una consulta SQL no lleva modelo.

Flujo

entrevista → ficha → plan (con revisor)
└ por capítulo: ensamblar contexto → Escritor → puertas deterministas
 → Editor → reescritura si hace falta → consolidar
 → Resumidor → puerta de capítulo

Memoria

Story bible en SQLite: hechos con sus usos por capítulo, cronología, fichas versionadas por t, resúmenes por capítulo, deltas persistidos y registro de conocimiento. El contexto se monta en siete bloques con orden de recorte y formas reducidas.

Dónde se van los tokens, medido

Dato	Valor	De dónde sale
Creación de caché frente a salida	9.476 vs 1.188 tokens	Primera escena medida
Reparto por agente	Escritor 75%, Juez 17%, Resumidor 7%	Escena con los tres
Coste por escena	0,3951 USD (3 agentes) · 0,47 USD (obra de 10 cap.)	E5b y obra larga
Obra completa de 10 capítulos	26,04 USD, 169 delegaciones, 78 min	Primera obra
Capítulo 1 de la novela regalo	3,77 USD en 7 llamadas, 3 intentos	Primera ejecución del pipeline nuevo
Contexto montado, máximo	4.352 tokens = 4,4% del techo de 100.000	Obra de 10 capítulos
cache_read	1.553 (Escritor), 1.572 (Juez)	Segunda ejecución

El hallazgo que gobierna el roadmap: el coste lo domina **montar el contexto**, no escribir. Y aislar al Juez —cuyo directorio no tiene CLAUDE.md— lo hizo **cuatro veces más barato**: 2.562 tokens de caché en vez de 8.434. La decisión se tomó por corrección y resultó ser la partida más rentable del ciclo.

Supuestos declarados, no medidos

- El coste del pipeline actual **con Editor** está sin medir. Las cifras de obra larga vienen del diseño anterior, sin Editor.
- El **contexto enviado real** está sin medir desde F-58: hasta entonces el número medía lo que se montaba, no lo que se enviaba, y sesgaba a la baja.
- El coste de una novela regalo completa está sin medir: la ejecución no pasó del capítulo 1.
- Los tokens que devuelve una tool se miden pero no se presupuestan (SPEC-28). Punto ciego declarado.

Fase 2 · Categorías

	Categoría	Qué agrupa
A	Coste de arranque por delegación	Creación de caché, A-03, qué CLAUDE.md ve cada agente, aislamiento por directorio
B	Ensamblado del contexto	Los siete bloques, orden de recorte, qué entra y qué no
C	Reintentos y reescrituras	Escritor rechazado, rondas del planificador, capítulos fuera de rango
D	Reparto de modelos por tarea	Qué agente usa qué modelo y si está bien asignado
E	Validación y juicio	Editor y Juez: cuánto de lo que juzga un modelo lo haría una regla

Fuera de alcance: código e infraestructura del agente, que no consume tokens de generación. La orquestación cae dentro de **A**, porque aquí el orquestador es código determinista.

Fase 3 · Informe por categoría

A · Coste de arranque por delegación

1. Situación. Es la partida mayor con diferencia: 9.476 tokens de creación de caché frente a 1.188 de salida. Cada agente paga su propio arranque por A-03 (un agente, una llamada, contexto propio). Con seis agentes y diez capítulos, eso son decenas de arranques por novela.

Hay una medida que lo demuestra: el Juez, aislado en un directorio sin CLAUDE.md, crea 2.562 tokens de caché en vez de 8.434. **Cuatro veces más barato, por no leer un fichero que no necesitaba.**

2. Estrategias.

Medida	Qué hace
Auditar qué CLAUDE.md ve cada agente	El Juez ya está aislado por corrección. Aplicar lo mismo al Resumidor y al Revisor, que tampoco necesitan las reglas del proyecto
Partir CLAUDE.md por audiencia	Un núcleo mínimo para los agentes de generación y el resto en ficheros que solo lee quien los necesita
Aprovechar el caché entre capítulos	El bloque inmutable —premisa, guía de estilo, anclas— es idéntico en los diez capítulos. Que sea el prefijo estable de cada prompt maximiza cache_read

Medida	Qué hace
⚠ Agrupar escenas por delegación	Menos arranques, pero contradice A-03 y pierde la atribución de fallos por escena, que es por lo que A-03 se eligió

3. Ahorro / esfuerzo. Auditar el CLAUDE.md de cada agente: **ahorro alto, esfuerzo bajo** — hay evidencia medida de 4x en un caso. Prefijo estable: **alto / medio**. Agrupar escenas: alto y **no recomendado**.

4. Riesgos. El aislamiento tiene un límite conocido: omitClaudeMd depende de una versión concreta de Claude Code y **falla en silencio** si no la reconoce. Si deja de aplicarse, el Juez vuelve a ver las reglas del proyecto y su desempate pasa a ser confirmación en vez de desempate. Mitigación: el validador que ya está previsto para comprobar que el aislamiento se aplica de verdad, no solo que está configurado.

5. Prioridad. La primera. Es donde está el dinero, hay evidencia medida y no toca la calidad.

B · Ensamblado del contexto

1. Situación. El contexto montado llega a 4.352 tokens sobre un techo de 100.000: **el 4,4%**. En una obra de diez capítulos **no se ejerció ni un solo recorte**.

Eso significa que todo el mecanismo de SPEC-12 —formas reducidas, la regla de que lo que lee una bloqueante no se reduce ni se elimina, la partición de Lugar— se diseñó para un régimen que el sistema no alcanza. No está mal: está sin ejercer, que es distinto.

Y hay un dato que lo relativiza: el número de 1.339 tokens que sostenía esa conclusión **medía lo que se montaba, no lo que se enviaba** (F-58). El contexto enviado real está sin medir.

2. Estrategias.

Medida	Qué hace
Medir primero el contexto enviado	Nada de esto se decide sin ese número. Es gratis: viaja en la siguiente generación
Ajustar el reparto a lo que se mide	15.000 para el inmutable y 25.000 para el local describen otro sistema
Recuperación por similitud en lugar de «todas las fichas»	sqlite-vec ya está enganchado y hoy no se usa para acotar
⚠ Reducir el bloque Local	Es el que más ocupa. La escena anterior completa es también lo que sostiene la continuidad inmediata

3. Ahorro / esfuerzo. Medir: **esfuerzo nulo, ahorro indirecto**. Ajustar el reparto: **bajo / bajo** — no ahorra por sí solo, quita ruido. Recuperación acotada: **medio / medio**, y crece con la longitud de la obra.

4. Riesgos. Alto y documentado. El bloque Local es exactamente lo que se arregló en F-40 y F-45: una novela que olvida el capítulo uno al empezar el dos. Y una escena escrita sin la anterior ni el estado del mundo **va a salir mal y consumirá una regeneración de todas formas**, así que recortar ahí no ahorra, traslada el gasto a la categoría C.

5. Prioridad. Segunda, y solo la medición por ahora. Con el contexto al 4,4% del techo, optimizar el ensamblado es optimizar lo que no duele.

C · Reintentos y reescrituras

1. Situación. Cada reintentado es **una delegación pagada completa**, con su arranque de caché incluido. Los datos:

- Capítulo 1 del regalo: **3 intentos, 7 llamadas, 3,77 USD**, y ni siquiera llegó a aceptarse.
- El plan: **3 rondas**, dos rechazadas por errores de formato del planificador (F-62), a una ronda de agotar el tope.
- Un intento se pasó del máximo de palabras: 1.564 sobre 1.500.
- Una parada fue **un falso positivo** (F-59): la palabra vetada «coño», al normalizar, acabó vetando la preposición «con». El Escritor no podía escribir una frase.

2. Estrategias. Todas van en la misma dirección: **que el prompt pida lo que el contrato exige**. Es un patrón que el proyecto ha encontrado cuatro veces.

Medida	Qué hace
Decir en el prompt qué campos admite el esquema	F-62: el planificador inventó un campo porque nadie le dijo cuáles había. Dos rondas perdidas
Pasar el rango de palabras al Escritor	Un intento fuera de rango es una delegación entera tirada por un número que se puede decir
Falsos positivos de los guardrails	F-59 costó dos reescrituras y una parada. La prueba que lo cierra —contrastar la lista de vetadas contra las palabras más frecuentes del español— caza la familia entera
Reescritura parcial en lugar de capítulo completo	Un hallazgo de una frase no necesita reescribir 1.300 palabras
Devolver los hallazgos del intento anterior	Ya existe el canal problemas. Sin él, la reescritura repite el error

3. Ahorro / esfuerzo. Prompts que piden lo que el contrato exige: **ahorro alto, esfuerzo muy bajo** — es redactar. Falsos positivos: **alto / bajo**. Reescritura parcial: **medio / alto**, y toca la verificación byte a byte del manuscrito.

4. Riesgos. Bajos, y en su mayoría **negativos**: menos reintentos por causas espurias mejora la calidad, no la empeora. La excepción es la reescritura parcial ⚠: un texto cosido de dos generaciones puede perder la voz, y el validador que compara el manuscrito con el borrador auditado exige identidad byte a byte.

5. Prioridad. La primera junto con A. Es la que mejor relación ahorro/esfuerzo tiene: casi todo es redactar prompts.

D · Reparto de modelos por tarea

1. Situación. Escritor con Fable, Editor y Juez con Opus 5.5, Resumidor con Haiku. El reparto de coste es 75 / 17 / 7.

El dato que lo gobierna: **los tokens no predicen el coste**. El Resumidor gastó más tokens que el Juez y costó menos de la mitad. Cualquier razonamiento por volumen es inválido aquí.

Y hay una restricción que no es de coste: el modelo del Juez **se fija dentro de una obra**, porque si cambia a mitad, dos capítulos dejan de ser comparables y nada lo avisaría. Además Fable enruta, así que una delegación puede tocar dos modelos legítimamente.

2. Estrategias.

Medida	Qué hace
Escritor: mantener el modelo capaz	Es el 75% del coste y es donde se juega la calidad. Abaratar aquí es el clásico ahorro que se paga en reescrituras
Modelo barato para tareas mecánicas	El Resumidor ya está en Haiku. Revisar si el Revisor del plan y la extracción de hechos del texto libre también pueden bajar

Medida	Qué hace
⚠ Editor a un modelo más barato	17% del coste, pero el Editor es lo que sostiene la calidad narrativa que el enunciado exige. No recomendado sin medir el acuerdo con la revisión humana
Modelo barato en el primer intento, capaz en el segundo	Idea atractiva y peligrosa: si el barato falla más, el coste sube

3. Ahorro / esfuerzo. Bajar las tareas mecánicas: **ahorro bajo-medio, esfuerzo bajo** (una variable de entorno). Tocar Escritor o Editor: **ahorro medio, riesgo alto**.

4. Riesgos. Altos donde más tienta. El Editor juzga la calidad narrativa, y ya hay un punto ciego declarado: **el Editor juzga el antes y el después del tuning**, así que la revisión humana es la segunda fuente. Degradarlo sin medir el acuerdo con esa revisión rompe la única referencia externa que hay.

5. Prioridad. Tercera. Ahorro modesto y el riesgo está mal repartido: lo barato de cambiar ahorra poco, lo que ahorraría es lo que no conviene tocar.

E · Validación y juicio

1. Situación. El proyecto ya ha recorrido este camino tres veces: **INV-03, INV-11 e INV-14 eran comparaciones disfrazadas de juicio**. INV-14 pedía un juez para comprobar si una lista de números decrece. INV-11 es un conteo. INV-03 es en su mayor parte comparar identificadores del registro de conocimiento.

Reclasificarlas hizo dos cosas a la vez: quitó llamadas al modelo y encogió el punto ciego de que la única puerta bloqueante dependiera de un juez cuya fiabilidad no está medida.

2. Estrategias.

Medida	Qué hace
Seguir buscando juicio que es comparación	Ya hay tres casos; el patrón no se ha agotado
Regla primero, juez solo de desempate	Es la forma de INV-03 hoy: la comparación determinista caza todo lo declarado y el juez solo ve lo que la regla no puede
Puertas deterministas antes del juez	Un capítulo que falla una puerta de código no necesita gastar un Editor
Aislar a los jueces	Doble efecto: más barato (4× medido) y mejor juicio, porque un desempate que ve lo mismo que la regla confirma en vez de desempatar
⚠ Reducir los criterios del Editor	Seis notas cuestan más que tres. Pero saltarse un criterio no dice que ese criterio esté bien

3. Ahorro / esfuerzo. Reclassificar: **ahorro medio, esfuerzo medio** — cada una necesita spec de dominio. Orden de puertas: **medio / bajo**. Aislamiento: ya contado en A.


4. Riesgos. Bajos, y esta categoría mejora la calidad mientras ahorra. Una regla determinista es reproducible y un juez no: la decisión 9 del sistema anterior demostró que sin poder fijar la temperatura, la puntuación deja de ser una medida y pasa a ser una comparación dentro de una misma generación.

El riesgo real es el contrario: **reclasificar a regla algo que sí necesitaba criterio**. Mitigación, ya aplicada — la regla no sustituye al juez, lo antepone.

5. Prioridad. Segunda. Ahorra y mejora a la vez, que es raro.

Fase 4 · Roadmap

Dependencias



Solapamientos resueltos: el aislamiento de agentes aparecía en A y en E; se cuenta en A y E solo hereda su beneficio. La reducción del bloque Local aparecía en B y arrastra a C; se descarta por eso.

Fase I · Ganancias rápidas (sin tocar la calidad)

#	Acción	Categoría	Ahorro	Esfuerzo
1	Auditar qué CLAUDE.md ve cada agente y aislar a los que no lo necesitan	A	Alto	Bajo
2	Decir en cada prompt qué campos admite su contrato	C	Alto	Muy bajo
3	Pasar el rango de palabras al Escritor	C	Medio	Muy bajo
4	Cerrar los falsos positivos de los guardrails con la prueba de la lista completa	C	Medio	Bajo
5	Instrumentar la medida del contexto enviado	B	—	Bajo

Las cinco son redacción o configuración. **Ninguna toca la calidad narrativa**, y las tres de la categoría C la mejoran, porque quitan reintentos por causas espurias.

Fase II · Mejoras estructurales

#	Acción	Categoría	Depende de
6	Prefijo estable en el prompt para maximizar cache_read entre capítulos	A	1
7	Ajustar el reparto por niveles a lo medido	B	5
8	Seguir reclasificando juicio que es comparación	E	—
9	Puertas deterministas antes de llamar al Editor	E	—
10	Recuperación por similitud en vez de todas las fichas	B	5, 7

Fase III · Optimización continua

#	Acción	Condición
11	Bajar el modelo de las tareas mecánicas restantes	Medir antes que no sube la tasa de rechazo
12	⚠ Reescritura parcial en vez de capítulo completo	Resolver la verificación byte a byte del manuscrito
13	⚠ Revisar el modelo del Editor	Solo con el acuerdo Editor-humano medido

KPIs

Indicador	Cómo se mide	Por qué
Coste por capítulo aceptado	USD por capítulo que pasa todas las puertas	El indicador principal. Un capítulo barato que se rechaza cuesta más que uno caro que pasa
Intentos por capítulo	Media de delegaciones del Escritor por capítulo aceptado	Aísla el gasto de la categoría C
Rondas de plan	Rondas hasta aprobar	Mide directamente la acción 2
Ratio caché / salida	Tokens de creación de caché entre tokens de salida	Mide A. Hoy es 8:1
cache_read entre capítulos	Tokens leídos de caché por capítulo	Mide la acción 6
Coste por agente	Reparto porcentual	Detecta si la auditoría cambia el peso relativo
Incidencias de continuidad	Hallazgos bloqueantes por novela	El freno. Si sube mientras el coste baja, la optimización está pagándose con calidad
Nota media del Editor por criterio	Antes y después de cada medida	Segundo freno, con la revisión humana como referencia externa

Regla de parada: cualquier medida que baje el coste y suba las incidencias de continuidad o la nota del Editor se revierte. El ahorro no es el objetivo; el coste por capítulo aceptable sí.

Resumen ejecutivo

El coste de este sistema no está en escribir, está en **montar el contexto**: ocho tokens de creación de caché por cada uno de salida. La evidencia más fuerte ya está medida — aislar al Juez de CLAUDE.md lo hizo cuatro veces más barato, y esa decisión se había tomado por corrección, no por coste.

Por eso la primera fase es auditar qué lee cada agente y arreglar los prompts que no piden lo que el contrato exige, que es lo que ha causado reintentos pagados en las dos últimas ejecuciones. Son medidas de redacción y configuración, sin riesgo para la novela, y varias **mejoran la calidad** al eliminar rechazos espurios.

Lo que no se toca todavía: el contexto ocupa el 4,4% del techo, así que optimizar el ensamblado es optimizar lo que no duele, y el número que lo sostiene está sesgado a la baja hasta que se mida el contexto enviado de verdad. Y el Escritor, que es el 75% del gasto, es también donde se juega la calidad que el encargo pone al mismo nivel que la personalización.